



引用格式: 黄勃学, 韩 玲, 王 昆, 等. 基于改进 YOLOv3 的合成孔径雷达影像舰船目标检测[J]. 科学技术与工程, 2021, 21(4): 1435-1441.  
Huang Boxue, Han Ling, Wang Kun, et al. Synthetic aperture radar image ship target detection based on improved YOLOv3 [J]. Science Technology and Engineering, 2021, 21(4): 1435-1441.

# 基于改进 YOLOv3 的合成孔径雷达 影像舰船目标检测

黄勃学, 韩 玲\*, 王 昆, 杨朝辉, 黄五超

( 长安大学地质工程与测绘学院, 西安 710054)

**摘 要** 为了提高合成孔径雷达( synthetic aperture radar, SAR) 影像舰船目标的召回率和准确率, 降低漏检率, 通过以 YOLOv3 ( you only look once) 为检测框架, 对锚点框( anchor boxes) 生成机制进行改进, 提出了利用  $K$ -median++ 生成 anchors 的聚类算法。结果表明不当的初始聚类中心会降低 anchor boxes 的平均交并比( mean intersection over union, meanIOU); 同时由于 SAR 舰船数据集存在少量大尺寸 box( 离群数据点), 因此在实验中使用中位数代替平均值, 对簇群计算聚类中心, 聚类后 anchor boxes 的 meanIOU 高达 77.10%, 在均值聚类算法(  $K$ -means clustering algorithm) 基础上提高了 3.7 个百分点, 并且减少了迭代次数, 计算量得到大幅度降低。可见相比传统基于  $K$ -means 的 YOLOv3, 检测效果有了明显提升, 召回率达到 92.21%, 均值平均精度( mean average precision, mAP) 达到 93.56%, 分别提高了 2.55、3.82 个百分点。

**关键词** 目标检测; 合成孔径雷达( SAR); YOLOv3; 聚类算法; 图像处理

中图分类号 TN957.51; 文献标志码 A

## Synthetic Aperture Radar Image Ship Target Detection Based on Improved YOLOv3

HUANG Bo-xue, HAN Ling\*, WANG Kun, YANG Zhao-hui, HUANG Wu-chao

( School of Geological Engineering and Surveying, Chang'an University, Xi'an 710054, China)

**[Abstract]** In order to improve the recall rate and accuracy rate of synthetic aperture radar ( SAR) image ship targets and reduce the missed detection rate, the anchor boxes generation mechanism was improved by using you only look once ( YOLOv3) as the detection framework, and a clustering algorithm of  $K$ -median++ to generate anchors was proposed. The results show that improper initial clustering center reduces the mean intersection over union ( meanIOU) of anchor boxes. At the same time, due to the existence of a small amount of large size boxes ( outlier data points) in SAR ship data sets, the median was used to replace the mean in the experiment, and cluster centers were calculated for cluster groups. The meanIOU of anchor boxes after clustering is as high as 77.10%, which increases by 3.7 percentage on the basis of  $K$ -means, and the number of iterations is reduced, which greatly reduces the calculation amount. It can be seen that compared with the traditional YOLOv3 based on  $K$ -means, the detection performance is significantly improved, with the recall rate reaching 92.21% and mean average precision ( mAP) reaching 93.56%, increasing by 2.55 and 3.82 percentage respectively.

**[Keywords]** target detection; synthetic aperture radar; YOLOV3; clustering algorithm; image processing

随着遥感技术的发展, 基于遥感影像进行舰船检测成为了沿海国家的重要任务, 并且在舰船寻找与救助、渔船监视、非法移民、保卫领土、反毒品以及舰船非法倾倒油污的监视管理等方面发挥着重要作用<sup>[1-2]</sup>。合成孔径雷达( synthetic aperture radar, SAR) 是一种主动探测的成像传感器, 成像不受云雾、光照的影响, 可以对目标实现多波段、多极化、多视角的观测<sup>[3]</sup>。在舰船检测任务中, SAR 不受海

洋天气多变的限制, 能够对舰船目标进行全方位实时监测。

**SAR 影像舰船检测**虽然起步较早, 但大部分研究是基于传统的目标检测思想, 仍然是半自动化的检测算法。近年来, 中外对 SAR 影像舰船检测开展了大量的研究。文献 [4-6] 提出了双参数恒虚警率( constant false alarm rate, CFAR) 算法; 加拿大商用软件 OMW ( ocean monitoring worksta-

收稿日期: 2020-04-28; 修订日期: 2020-07-25

基金项目: 装备预研教育部联合基金( 6141A02022376)

第一作者: 黄勃学( 1995—), 男, 汉族, 甘肃庆阳人, 硕士研究生。研究方向: 目标检测及图像处理。E-mail: 1521590770@qq.com。

\* 通信作者: 韩 玲( 1964—), 女, 汉族, 辽宁沈阳人, 博士, 教授。研究方向: 摄影测量与遥感。E-mail: hanling@chd.edu.cn。

投稿网址: www.stae.com.cn

tion)<sup>[7]</sup>使用基于  $K$  分布的 CFAR 算法进行舰船检测;Kapur 等<sup>[8]</sup>将信息论中的熵引入图像分割,提出了最佳熵双阈值检测算法;Tello 等<sup>[9]</sup>、Wardlow<sup>[10]</sup>使用小波变换来检测舰船目标;张风丽等<sup>[11]</sup>提出了基于小波变换和相关运算结合的舰船目标检测算法;Liu 等<sup>[12]</sup>利用多极化特性进行舰船目标检测。

近年来,随着深度学习在各学科的泛化发展,目标检测算法也有了实质性进展,推动了 SAR 影像舰船检测任务从半自动化进入到全自动化时代。目前比较流行的检测算法可以分为两大类。一类是基于区域建议(region proposal)的分步式目标检测方法,代表性的有:区域卷积神经网络(region-based convolutional neural networks, R-CNN)<sup>[13]</sup>、SPP(spatial pyramid pooling)<sup>[14]</sup>、Fast R-CNN<sup>[15]</sup>、Faster R-CNN<sup>[16]</sup>,这些是 two-stage 算法,需要先使用选择性搜索(selective search)或者区域建议网络(region proposal networks, RPN)产生建议区域,然后再在建议区域上进行边框回归和二次分类,实现目标检测;另一类是基于回归思想的一步式目标检测方法,代表性的有:YOLO(you only look once)<sup>[17]</sup>、SSD(single shot multibox detector)<sup>[18]</sup>等,这些是 one-stage 算法,将目标检测问题简化为回归问题,没有显式的区域提名过程,仅使用一个卷积神经网络直接预测不同目标的类别和位置。为此,以 one-stage 的 YOLOv3 算法作为框架基础,对锚点框(anchor boxes)生成机制进行改进,并与多种聚类算法进行对比分析,以期提高 YOLOv3 舰船检测的效果。

## 1 YOLOv3 基本原理

YOLOv3 是在 YOLOv2 基础上改进而来的目标检测模型,是目前速度和精度最为均衡的检测网络,它采用一个单独的卷积神经网络(convolutional neural networks, CNN)实现 end-to-end 的目标检测。

YOLOv3 相比 YOLOv2,进行如下改进:①加入了多尺度预测,借鉴特征图金字塔网络(feature pyramid networks, FPN)思想,通过融合多层特征映射信息预测 3 种不同尺度的先验框;②使用  $K$ -means 聚类得到边界框(bounding box)的先验框,选择 9 个簇以及 3 个尺度,然后将这 9 个簇均匀分布在这 3 个尺度上,即每种尺度预测 3 个 anchor boxes,对于每种尺度,引入新的卷积层进一步提取特征,最后在各尺度上输出边界框(bounding box)的信息;③分类器不再使用 softmax,而是使用独立的多个 logistic

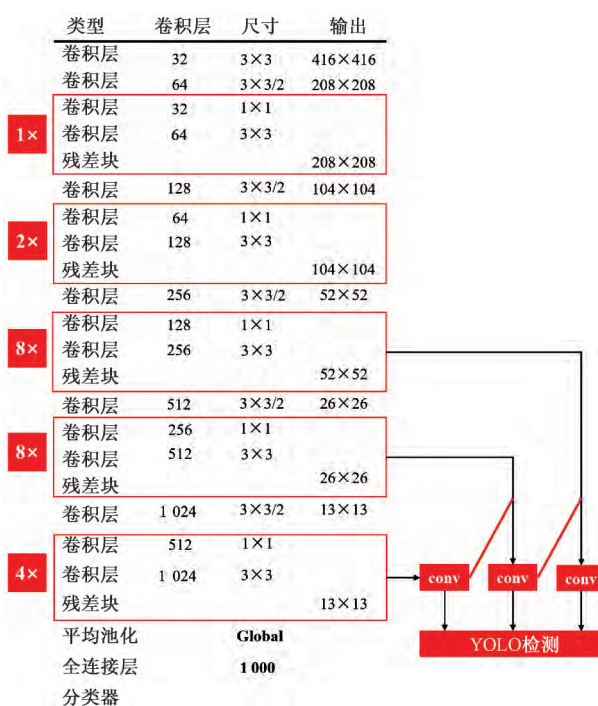


图1 Darknet-53 网络结构

Fig. 1 Darknet-53 network architecture

分类器代替;④在训练过程中,使用二元交叉熵损失(binary cross-entropy loss)来进行类别预测;⑤用 Darknet-53 代替 Darknet-19 进行特征提取,如图 1 所示,即借鉴残差网络<sup>[19]</sup>的思想,交替使用 3×3 与 1×1 的卷积神经网络,简化了 ResNet 神经网络,加快训练速度。

## 2 舰船目标检测框架

### 2.1 舰船目标检测流程

舰船目标检测的整体流程如图 2 所示。

### 2.2 锚点框算法改进

anchor boxes 是用来预测边界框(bounding box)的,锚点框算法最初是在 Faster R-CNN 中提出的,原文用 128×128、256×256、512×512 尺度,以及 1:1、1:2、2:1 纵横比共计 9 个 anchors 来预测边界框。每个 anchor 预测 2 000 个框左右,使得目标检出率大大提高。从 YOLOv2 开始增加了锚点框机制,到 YOLOv3 已由 5 个增加到了 9 个 anchors。由于作者是在 PASCAL VOC 数据集得到的这组 anchor,对于自然数据集比较敏感,但是对于遥感影像数据集,尤其是 SAR 数据集来说,宜使用新的锚点框组合进行数据集的训练。在数据集 11 853 张船舰 SAR 影像中,共有 16 174 只船舰目标,以标注框的标准化宽高作为坐标维度,可视化数据集分布,如图 3 所示,可以发现 95% 以上的目标的尺寸集中在 0.5×0.5,并且数据聚集特别紧密,存在少

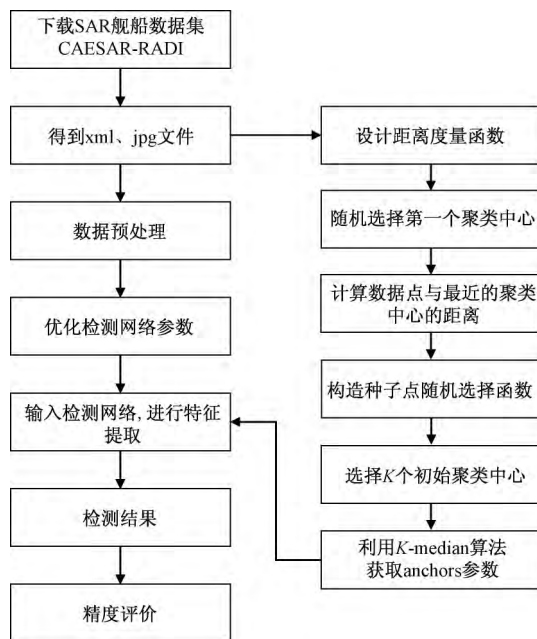


图2 舰船目标检测流程

Fig. 2 Ship target detection process




图3 SAR 舰船数据集可视化

Fig. 3 SAR ship data set visualization

部分离群样本。还对训练集标注框的标准化宽高进行统计分析,如图4、图5所示,发现有83.45%和83.10%的目标标准化宽高分布于0.02~0.18,也就是说绝大部分目标不足图像1/10,因此SAR舰船数据集的小目标居多。

对于距离的选择,如果按照传统K-means算法使用欧氏距离,则大的boxes会比小的boxes产生更多的损失误差。YOLO作者在设计锚点框思想时希望通过anchor boxes获得更好的IOU scores,并且IOU scores与bounding box的尺寸无关,为此设计了新的距离公式为

$$d(\text{box}, \text{centroid}) = 1 - \text{IOU}(\text{box}, \text{centroid}) \quad (1)$$

式(1)中: box 为各 anchor box; centroid 为当前簇群的定位框; IOU(box, centroid) 为 anchor 和当前定位框的交并比。




图4 SAR 舰船数据集标注框宽度统计结果

Fig. 4 Statistical results of the box width of SAR ship data set




图5 SAR 舰船数据集标注框高度统计结果

Fig. 5 Statistical results of the box height of SAR ship data set

## 2.2.1 K-median++

由于K-means算法需要不断的更换聚类中心,通过平均值来重新计算每个簇群的中心。对于数据聚集紧密且有明显离散点的数据,使用平均值确定聚类中心会使处于离散点簇的中心不稳定,容易受到噪声点的影响;同时K-means算法初始聚类中心需要人为确定,不同的初始聚类中心可能导致完全不同的聚类结果。针对这两点不足,对于YOLOv3的锚点框聚类算法进行改进,以使其更加符合舰船SAR影像数据集的特点,得到更能反映舰船样本尺寸的anchors参数。

对于数据离散点较多,致使尺寸较大的 bounding box 的簇群的中心不能被真实反映,用中位数代替均值计算新的聚类中心。这样针对数据集中某些离群点,中位值的变化也不是很大,甚至无变化,因此鲁棒性会比K-means好很多;对于初始聚类中心的选择,应使初始聚类中心之间的相互距离要尽可能的远。因此将本文的聚类方法命名为K-median++。

## 2.2.2 K-median++ 算法实现

K-median++ 算法实现伪代码如下。



(1) 从数据集点群随机选择一个点作为第一个聚类中心。

(2) 对于数据集中的每一个点  $X$ , 计算其与最近的聚类中心(指已选择的聚类中心)的距离, 记为  $D(X)$ 。

(3) 再从数据集中随机挑选一个随机点作为“种子点”。

(4) 对于每个点  $X$ , 计算其与最近的一个“种子点”的距离并保存在一个数组中, 然后把这些距离加起来得到  $\text{Sum}[D(X)]$ 。

(5) 取一个能落在  $\text{Sum}[D(X)]$  中的随机值  $\text{Random}$ , 执行  $\text{Random} = D(X)$ , 直到  $\text{Random} \leq 0$ , 此时的点就是下一个“种子点”。

$\text{Random}$  的取法: 为使  $\text{Random}$  落在  $\text{Sum}[D(X)]$  中, 设计  $\text{Random} = \text{Sum}[D(X)]\alpha$ , 其中  $0 < \alpha < 1$ ,  $\text{Random}$  是随机的, 那么它有更大的概率落在  $D(X)$  较大的区域内, 如图 6 所示,  $\text{Random}$  更有可能落在  $D(X_i)$  中,  $X_i$  为数据集的第  $i$  个点; 此时利用  $\text{Random} = D(X)$ , 直到  $\text{Random} \leq 0$ , 便可知道  $\text{Random}$  落在了哪个区间段, 因此  $X_i$  就是下一个选择的随机聚类中心。

(6) 重复步骤(2)~(5), 直到  $K$  个初始聚类中心被选择出。

(7) 利用  $K$  个初始聚类中心, 执行  $K$ -median 聚类算法。

在对数据集进行预处理之后, 利用  $K$ -means、 $K$ -means++、 $K$ -median 及  $K$ -median++ 4 种算法进行聚类, 并以各自的  $\text{meanIOU}$  作为评价标准, 对比结果如表 1 所示。

对 4 种聚类算法的  $\text{meanIOU}$  变化曲线可视化, 如图 7(a) 所示,  $K$ -means 在第 7 次迭代时  $\text{meanIOU}$  到达峰值 74.52%, 之后随着迭代的收敛,  $\text{meanIOU}$  呈缓慢下降趋势, 最终经过 34 次迭代,  $\text{meanIOU}$  达到 73.40%; 如图 7(b) 所示,  $K$ -means++ 与  $K$ -means 的曲线走势大致相同, 在第 6 次迭代  $\text{meanIOU}$  达到峰值 75.60% 之后会缓慢下降, 最终经过 26 次迭代,  $\text{meanIOU}$  达到 75.41%, 相比  $K$ -means 提升了 2.01 个百分点; 如图 7(c) 所示,  $K$ -median 并未出现  $\text{meanIOU}$  随迭代而明显下降的问题, 同时, 仅通过 17 次迭代,  $\text{meanIOU}$  便稳定在了 74.99%, 相比  $K$ -means





图 6 随机聚类中心选择

Fig. 6 Random cluster center selection


表 1 4 种聚类算法的对比结果

Table 1 Comparison results of four clustering algorithms


聚类算法	平均交并比/%	迭代次数
$K$ -means	73.40	34
$K$ -means++	75.41	26
$K$ -median	74.99	17
$K$ -median++	77.10	9




(a)  $K$ -means 平均交并比变化曲线



(b)  $K$ -means++ 平均交并比变化曲线



(c)  $K$ -median 平均交并比变化曲线



(d)  $K$ -median++ 平均交并比变化曲线

图 7 平均交并比变化曲线

Fig. 7 The curve of the mean intersection over union

提升了 1.59 个百分点; 如图 7(d) 所示,  $K$ -median++ 的整个曲线走势是很平稳地上升, 并且起始聚类的 meanIOU 高达 73.04%, 这一点和  $K$ -means++ 很相近, 这也是自动生成初始聚类中心算法的突出优势, 初始聚类中心的选取很可靠, 因此后续达到收敛要求迭代次数少, 在经过 9 次迭代之后, meanIOU 稳定在了 77.10%, 相比  $K$ -means 提升了 3.7 个百分点。因此经过对比发现  $K$ -median++ 作为 YOLOv3 的锚点框聚类算法是可行的, 相比其他三种聚类算法, meanIOU 最高, 迭代次数最少, 可以使 anchor boxes 的精度得到较大的提高, 计算量得到大幅度降低。

### 3 实验

#### 3.1 实验平台

本文算法在开源目标检测框架 Darknet 上实现, 具体相关配置环境如表 2 所示。

表 2 实验配置环境

Table 2 Experimental configuration environment

名称	配置
CPU	i5-9300H CPU @ 2.40 GHz
内存	16 GB
GPU	NVIDIA GeForce GTX1650
显存	6 GB
GPU 加速库	CUDA 10.1 CUDNN 7.6
操作系统	Windows10
深度学习框架	Darknet

#### 3.2 数据集获取

由于遥感影像数据集较为缺乏, 目前大部分目标检测数据集都是真实场景数据, 如 PASCAL VOC2007/2012、COCO 等数据集; 近年来, 由部分机构、高校带头做了不少的遥感数据集, 如 DOTA、NWPUVHR-10、RSOD 等。数据集是 SAR 舰船图片, 采用中科院遥感所王超团队构建的“多模式 SAR 图像船舶检测数据集——CAESAR-RADI”, 选取其中 11 853 张图片。然后将数据集分为训练集、验证集、测试集, 分别用于模型训练、参数调优和结果评价。

#### 3.3 实验步骤

①将制作好的训练集的 xml 标注文件转换为对应的 txt 标注文件; ②生成训练集、验证集、测试集图像路径列表; ③调整优化部分网络参数, 网络配置参数如下(动量: 0.9; 权重衰减: 0.0005; 饱和度: 1.5; 曝光度: 1.5; 色调: 0.1; 最大迭代次数: 2000; 学习率: 0.01、0.001、0.0001); ④利用  $K$ -means 脚本和  $K$ -median++ 脚本得到训练集的 9 种 anchors 组合; ⑤修改类名文件 names 和 data 文件; ⑥加载预训练模型 darknet53.conv.74 加快网络收敛; ⑦将  $K$ -means

算法和  $K$ -median++ 算法得到的两种 anchors 组合分别嵌入网络配置文件, 生成各自的训练权重文件。

#### 3.4 实验结果

对训练集分别用  $K$ -means 和  $K$ -median++ 生成的 anchors 参数进行训练, 得到各自的权重文件, 再进行结果评估。模型训练的损失函数曲线如图 8 所示, 初始迭代损失(loss)高达 974, 随着迭代进行, 在第 70 次迭代时, 损失值已降到了个位数, 在前 500 次迭代中, YOLOv3( $K$ -means) 和 YOLOv3( $K$ -median++) 的损失值差距不明显, 曲线基本相互重叠; 当迭代进行到 600 次时, 两条损失曲线之间的差距逐渐拉开, 后者较前者学习能力更强, 收敛速度更快, 训练效果更好。

##### 3.4.1 舰船检测结果

在训练好 YOLOv3( $K$ -means) 和 YOLOv3( $K$ -median++) 的权重文件之后, 在测试集上进行检测, 检测结果如图 9 所示。由图 9 可以发现, YOLOv3( $K$ -median++) 对于小目标的检测有了明显提升, 使得更多的舰船目标被检测出来。

##### 3.4.2 评价指标

实验结果评价采用国际 PASCAL VOC 目标检测挑战赛的度量标准, 即精确度(Precision)、召回率(Recall)、平均精度(AP)和平均精度均值(mAP)。精确率和召回率定义为

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3)$$

式中: TP 为预测对的正样本; FP 为预测错的正样本; TN 为预测对的负样本; FN 为预测错的负样本。精确率是针对预测结果而言, 预测为正的样本中有多少是真正的正样本, 即预测的正样本中有多少是预测对的; 召回率是针对数据集中的正样本而言, 表示数据集中正样本有多少被正确预测到, 即有多

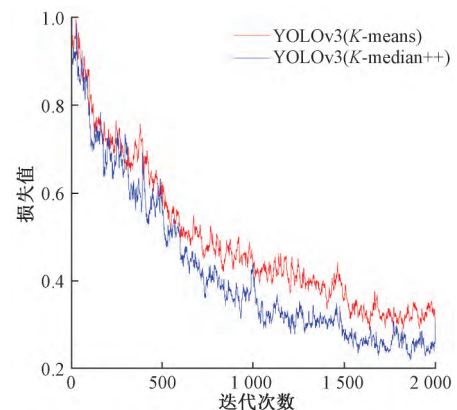


图 8 损失函数曲线

Fig. 8 Loss function curve



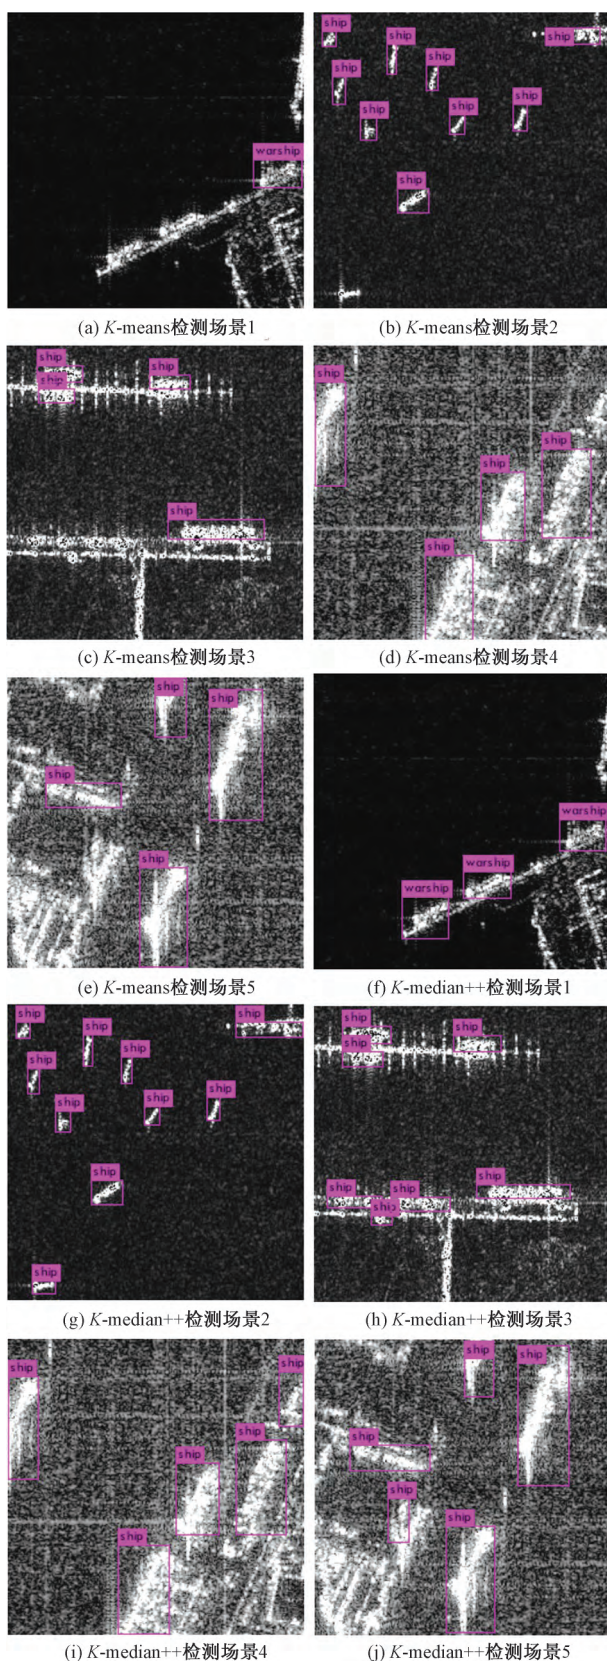


图9 SAR影像舰船检测结果

Fig.9 SAR image ship detection results

少正样本被正确检出。最终舰船目标检测结果评估如表3所示。

表3 舰船目标检测结果评估

Table 3 Evaluation of ship target detection results

算法	Recall/%	mAP/%
YOLOv3( K-means)	89.66	89.74
YOLOv3( K-medians++ )	92.21	93.56

## 4 结论

通过改进 YOLOv3 的 anchor boxes 聚类方法,提出了新的聚类算法 K-medians++,通过对舰船 SAR 数据集的标注框进行聚类分析,获得了更为合理的 anchors 参数。得出如下结论。

(1) 相较于传统的 K-means 聚类方法, K-medians++ 聚类算法对紧密数据集有更好的鲁棒性。相比 K-means、K-means++、K-medians 3 种聚类方法,通过 K-medians++ 得到的聚类中心更为合理,大幅度降低计算量,同时获取的 anchor boxes 可以保持较高的 meanIOU; K-medians++ 算法不仅适用于本文数据集,也适用与类似紧密型聚集数据的聚类。

(2) 基于 K-medians++ 的 YOLOv3 检测效果也更为出色,对于不同尺寸的舰船目标都能保证较高的检测准确率,同时召回率获得了明显提升,即有更多不明显舰船目标会被检测出。

## 参考文献

- [1] 唐沐恩,林挺强,文贡坚. 遥感图像中舰船检测方法综述[J]. 计算机应用研究,2011,28(1): 29-36.  
Tang Muen, Lin Tingqiang, Wen Gongjian. Overview of ship detection methods in remote sensing image[J]. Application Research of Computers, 2011, 28(1): 29-36.
- [2] 曹立杰,郭戈,王其华,等. 一种海面目标定位跟踪方法[J]. 科学技术与工程,2015,15(26): 89-93.  
Cao Lijie, Guo Ge, Wang Qihua, et al. A method of surface target location and tracking control[J]. Science Technology and Engineering, 2015, 15(26): 89-93.
- [3] 胡显,姚群力,侯冰倩,等. 基于卷积神经网络的合成孔径雷达图像目标识别[J]. 科学技术与工程,2019,19(21): 228-232.  
Hu Xian, Yao Qunli, Hou Bingqian, et al. Target recognition using convolution neural network for SAR images[J]. Science Technology and Engineering, 2019, 19(21): 228-232.
- [4] Eldhuset K. An automatic ship and ship wake detection system for spaceborne SAR images in coastal regions[J]. IEEE Transactions on Geoscience and Remote Sensing, 1996, 34(4): 1010-1019.
- [5] Casasent D P, Wei Su, Turaga D, et al. SAR ship detection using new conditional contrast boxfilter[J]. Proceedings of the International Society for Optical Engineering, 1999, 3721: 274-284.
- [6] Wackerman C C, Friedman K S, Pichel W G, et al. Automatic detection of ships in RADARSAT-1 SAR imagery[J]. Canadian Journal of Remote Sensing, 2001, 27(5): 568-577.
- [7] Vachon P W, Thomas S J, Cranton J, et al. Validation of ship de-

- tection by the RADARSAT synthetic aperture radar and the ocean monitoring workstation [J]. Canadian Journal of Remote Sensing, 2000, 26(3): 200-212.
- [8] Kapur J N, Sahoo P K, Wong A K C. A new method of gray-level picture thresholding using the entropy of the histogram [J]. Computer Vision Graphics and Image Processing, 1985, 29(2): 273-285.
- [9] Tello M, López-Martínez C, Mallorquí J J, et al. A novel algorithm for ship detection in SAR imagery based on the wavelet transform [J]. IEEE Transactions on Geoscience and Remote Sensing Letters, 2005, 2(2): 201-205.
- [10] Wardlaw B D, Egbert S L, Kastens J H. Analysis of time-series MODIS 250 m vegetation index data for crop classification in the U.S. Central Great Plains [J]. Remote Sensing of Environment, 2007, 108(3): 290-310.
- [11] 张凤丽, 吴炳方, 张磊. 基于小波分析的 SAR 图像船舶目标检测 [J]. 计算机工程, 2007, 33(6): 33-34.  
Zhang Fengli, Wu Bingfang, Zhang Lei. Ship detection in SAR image based on wavelet analysis [J]. Computer Engineering, 2007, 33(6): 33-34.
- [12] Liu C, Vachon P W, Geling G W. Improved ship detection using polarimetric SAR data [C]//Geoscience and Remote Sensing Symposium. New York: IEEE, 2004: 1800-1803.
- [13] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for object detection and semantic segmentation [C]//IEEE Conference on Computer vision and pattern Recognition (CVPR). Columbus: IEEE, 2014: 580-587.
- [14] He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2014, 37(9): 1904-1916.
- [15] Girshick R. Fast R-CNN [C]//Proceedings of IEEE International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2015: 1440-1448.
- [16] Ren S, He K, Girshick R, et al. Faster R-CNN: towards real-time object detection with region proposal networks [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149.
- [17] Redmon J, Divvala S, Girshick R, et al. You only look once: unified, real-time object detection [C]//IEEE Conference on Computer Vision and Pattern Recognition (CVPR). San Francisco: IEEE, 2015: 6517-6525.
- [18] Liu W, Anguelov D, Erhan D, et al. SSD: single shot multi-box detector [C]//European Conference on Computer Vision. Berlin: Springer International Publishing, 2015: 21-37.
- [19] 杨剑, 刘方涛, 张涛, 等. 基于改进型残差网络烟雾图像识别 [J]. 科学技术与工程, 2019, 19(32): 236-243.  
Yang Jian, Liu Fangtao, Zhang Tao, et al. Smoke image recognition based on improved residual network [J]. Science Technology and Engineering, 2019, 19(32): 236-243.