



战术导弹技术
Tactical Missile Technology
ISSN 1009-1300, CN 11-1771/TJ

《战术导弹技术》网络首发论文

题目: 雷达回波信号的深度学习目标检测识别方法研究
作者: 宋海凌, 孙宇航, 何良, 程义琼
收稿日期: 2020-12-17
网络首发日期: 2021-03-24
引用格式: 宋海凌, 孙宇航, 何良, 程义琼. 雷达回波信号的深度学习目标检测识别方法研究[J/OL]. 战术导弹技术.
<https://kns.cnki.net/kcms/detail/11.1771.TJ.20210322.1052.012.html>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

雷达回波信号的深度学习目标检测识别方法研究

宋海凌¹, 孙宇航^{2*}, 何良², 程义琼²

(1. 海军研究院, 北京 100161; 2. 北京华航无线电测量研究所, 北京 100013)

摘要：在雷达目标检测识别领域，干扰技术不断升级，针对复杂场景环境下的海面目标检测任务，提出一种基于深度学习的雷达回波信号的目标检测识别方法，以解决传统方法迁移适应力不足问题。通过剖析雷达导引头数据特性，对比雷达回波数据同可见光数据差异，并对海面舰船和干扰两类目标雷达回波数据进行试验分析，将原本适用于可见光数据域的深度神经网络目标检测识别模型迁移至雷达回波数据域中；并进行轻量化模型试验，以便后续嵌入式开发工作。最后，在相关雷达回波数据集上，开展了模型训练和算法验证，并取得了较优异的结果，验证了深度神经网络模型在雷达数据领域中的可行性和有效性。

关键词：人工智能；导引头；目标识别

中图分类号：TJ761.1

文献标识码：A

文章编号：1009-1300(XXXX)XX-0001-10

DOI：10.3873/j.issn.1009-1300.2021.9.114

Research on Deep Learning Target Detection and Recognition Method Based on Radar Echo Signal

Song Hailing¹, Sun Yuhang^{2*}, He Liang², Cheng Yiqiong²

(1. Naval Research Academy, Beijing 100161, China;

2. Beijing Huahang Radio Measurement Institute, Beijing 100013, China)

Abstract: In the field of radar target detection and recognition, jamming technology is constantly upgraded. In order to solve the problem that traditional method of migration inadequate adaptive in facing sea surface target detection task under complex scene environment, a target detection and recognition method of radar echo signal based on deep learning is proposed. By dissecting the data characteristics of radar seeker data, the difference between radar echo and visible light data is compared, and sea surface ships and jamming targets are analyzed experimentally. The target detection and recognition deep neural network model, which is originally suitable for visible light data domain, is transferred to the radar echo data domain. Lightweight model experiment is carried out to facilitate the embedded development work. The feasibility and availability of the deep neural network model in radar data field is verified by the remarkable performance which obtained in the model training and algorithm validation on relevant radar echo data set.

收稿日期：2020-12-17

通讯作者：孙宇航，工程师。研究方向为 领域。

引用格式：宋海凌，孙宇航，何良，等. 雷达回波信号的深度学习目标检测识别方法研究 [J]. 战术导弹技术, XXXX, (XX): 1-10. (Song Hailing, Sun Yuhang, He Liang, et al. Research on Deep Learning Target Detection and Recognition Method Based on Radar Echo Signal [J]. Tactical Missile Technology, XXXX, (XX): 1-10.)

Key words: artificial intelligence; seeker; target recognition

1 引言

雷达技术是目标探测领域的一项重要手段,其全天候、全天时的工作特点,被广泛应用于军事领域和社会生产。随着深度神经网络技术的快速发展,目标检测任务的准确率取得了显著提升,使得目标检测算法可以应用于安防、金融、智能交通等领域,然而当前主流先进算法模型主要针对可见光图像或视频数据,对于雷达领域数据的相关研究相对较少。

针对海面场景的目标检测是雷达应用领域的一个重点研究问题。受复杂海洋环境产生的海杂波以及海面目标类型多样化的影响,海面目标检测的难点主要在于雷达回波数据本身,由于其特殊性,较可见光数据更为复杂,有效目标区域占比更加微小,颜色、边缘、纹理信息更加不明显,而随着海面场景的日益复杂化和相关干扰的升级换代,导引头视场内真假目标多、干扰样式多,使得雷达目标检测识别任务难度远远高于深度神经网络所针对数据域。而且由于雷达导引头同光学仪器采集方式的差异,使得雷达回波数据信噪比不高,进一步加大了检测识别任务的难度。

经典的检测方法通常基于统计理论,将海杂波视为随机过程,由于目标和杂波模型的多样化,该类方法在复杂背景下面临两难的参数选择问题,难以实现高性能检测。相比传统的目标检测算法,基于深度神经网络的目标检测性能取得了较大的突破。Girshick 等人提出基于卷积特征的两阶段检测网络(R-CNN, Regions with convolutional neural network features)^[1-3],首次将卷积神经网络用于目标检测领域。此后,单阶段的卷积神经网络检测框架相继出现^[4-6],使得目标检测任务成为了当前深度神经网络领域研究的热门方向。

在雷达目标识别领域,美国“LRASM”项目是最具代表性的应用人工智能技术的项目,通过人工智能技术,使得导弹具备自主感知威胁、自主在线航迹规划、目标识别等功能^[7-9]。国内相关

研究则针对航迹规划、目标测轨等领域展开研究,综合来看,当前针对雷达回波数据特性分析及深度神经网络检测识别算法的相关研究尚处于初步阶段^[10-11]。

因此,如何将当前性能优异的深度神经网络模型迁移至雷达数据领域、设计更有效的特征提取算法和数据预处理机制,成为研究该领域任务的关键。为解决上述问题,本文提出了一种基于深度神经网络的雷达导引头目标检测识别算法,其主要贡献在于:

(1) 针对雷达回波数据目标检测识别任务,提出一种基于距离-多普勒二维回波图像的多尺度金字塔目标检测网络。

(2) 针对深度神经网络模型采用轻量化网络结构模型进行对比试验,便于后续嵌入式开发。

2 本文方法

本文提出方法主要包含两部分内容:

(1) 针对雷达回波目标,基于特征金字塔多尺度的目标检测识别深度神经网络设计。

(2) 针对模型压缩任务,轻量化特征提取网络模型结构设计。


2.1 基于雷达回波数据的特征金字塔目标检测网络设计

同传统可见光数据相比,雷达回波目标在距离-多普勒(Range-Doppler, R-D)数据上占据数据单元较少,该类目标的特点是空间尺寸较小、速度变化缓慢,因此在 R-D 数据上仅有少数几个甚至单个数据点反映其特征,色彩、纹理特性表征能力较弱,即目标特征信息少。实际应用场景中,为使算法能够适应不同目标类型的检测任务,本章研究算法对雷达回波数据目标检测的改进策略。卷积神经网络通过对输入数据进行多次卷积、非线性映射和降采样操作提取数据特征。其中,降采样操作会使输出特征图逐层收缩,导致特征损失,进而造成漏检。雷达回波目标本身在输入数据中所占的数据单元较少,经过多次降采样后


目标的特征损失更大,这导致其在输出特征图上的语义信息十分微弱,进而使得检测模型无法感知目标。

针对雷达回波数据目标检测识别任务,本文基于特征金字塔目标检测网络 (Feature Pyramid Networks for Object Detection, FPN) 作为基本框架进行优化设计^[12]。特征金字塔伴生于神经网络中的降采样操作,神经网络中随着网络逐层降采样,各层输出的特征图不断缩小,每一层对应一个特定的缩放尺度,不同尺度的特征图本身形成了一个特征金字塔,在不同层特征图上可以利用不同尺度的特征检测目标。但是值得注意的是在单层特征图上检测目标时,网络并没有综合利用目标高层和低层的特征,如图1所示的网络结构。FPN实现了不同抽象程度特征的高效融合,在图1(a)所示特征金字塔架构的基础上,使用连续上采样操作将高层特征逐渐扩大,再分别与相同大小的低层特征图融合。融合后的特征同时具备了低层视觉信息和高层语义信息,优化了网络的检测性能。具体而言,FPN主要包括自底向上的路径和自顶向下的路径。自底向上的路径是卷积神经网络的前馈计算。自顶向下的路径首先通过对语义信息强的高层特征图进行上采样操作,通过最邻近上采样方法放大特征图,然后侧向连接从底向上的路径,每个横向连接自底向上路径和自顶向下路径的特征图,通过按元素相加,将上采样映射与相应的自底而上的特征融合。图1(b)在多个融合特征图上逐层检测目标,具有更高的检测正确率,图1(c)在融合后的特征图上进行单一尺度的检测,检测时间更短。由于网络各个位置输出的特征图存在通道数的差异,网络在和最后一个底层特征图融合时,需要额外增加一个横向连接器,如图2所示,即利用 1×1 卷积核将不同尺度下的卷积特征处理为相同通道数,特征融合过程在相邻层特征金字塔上迭代进行,直到生成最终的融合特征图。


根据特征金字塔思想的启发,本文结合R-D数据非对称的特点,在原始的目标检测网络中加入特征金字塔结构,改进后的检测网络结构示意图如图3所示,模型命名为AD-CNN (Asymmetric



(a) 普通特征金字塔



(b) 多尺度融合多尺度预测特征金字塔



(c) 多尺度融合单一预测特征金字塔

图1 网络结构图




图2 目标检测识别模型横向连接器

Detection Convolutional Neural Network)。检测目标时,输入的R-D数据在共享卷积层部分经变形卷




图3 加入特征金字塔后的AD-CNN算法

积核提取特征和降采样后,通过横向连接器将不同尺度的特征逐层融合。候选区域推荐网络(Region Proposal Network, RPN)分别在不同尺度的融合特征图上对候选区域进行目标/背景粗识别和感兴趣区域推荐,RPN过程如图4所示,卷积特征图先经过 3×3 滑动窗口处理,滑动窗口对特征图上的每个坐标点自动生成的3种固定大小、3种固定比例,共9种锚点框,锚点框经过卷积处理得到256-d特征,256-d特征分别经过分类全连接层和回归全连接层输出相应感兴趣区域的概率得分和坐标(图4中 k 取9)。最后将感兴趣区域输入到RCNN网络中进行精细的多目标分类和位置回归精调。

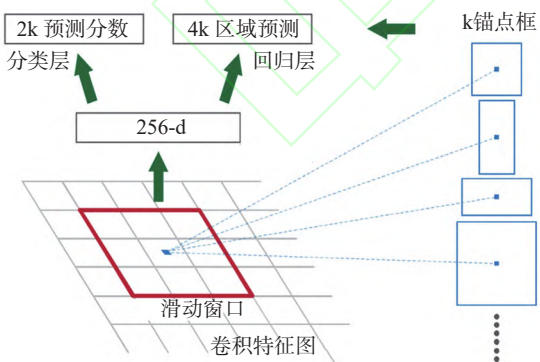


图4 RPN结构图

本文综合考虑雷达回波目标信息表征能力较弱的问题,加入特征金字塔结构,使得共享卷积RPN网络结构能够更好地提升不同类别数据的特征共享和信息关联能力,从而更好地处理细粒度

目标类别检测识别问题。

2.2 基于深度可分离卷积的轻量化网络结构设计

由于嵌入式硬件实现平台的存储空间相对算法的模型参数空间有限,为减少模型所需存储与计算资源,同时利用深度学习模型的冗余与容错特性实现高效深度模型参数的压缩,主要从网络结构设计层面对模型进行轻量化的结构优化。

Howard等提出了一种轻量高效的卷积神经网络模型(Efficient Convolutional Neural Networks for Mobile Vision Applications, MobileNet)^[13]。MobileNet的基本单元是深度可分离卷积,深度可分离卷积其实是一种可分解卷积操作,其可以分解为两个更小的操作:深度卷积和像素卷积。如图5所示,深度卷积和标准卷积不同,对于标准卷积,其卷积核是用在所有的输入通道上,而深度卷积针对每个输入通道采用不同的卷积核,即一个卷积核对应一个输入通道,因此,深度卷积是深度级别的操作。而像素卷积本质上是采用 1×1 卷积核的普通卷积。对于深度可分离卷积,其首先采用深度卷积对不同输入通道分别进行卷积,然后采用像素卷积将上面的输出再进行结合,其整体效果




图5 深度级卷积和像素级卷积

和一个标准卷积相差不大,但是会大大减少计算量和模型参数量。

深度可分离卷积是 MobileNet 的基本组件,但是在实际应用中会加入批归一化层,并使用修正线性激活函数,深度可分离卷积的基本结构如图 6 所示。




图6 加入批归一化层和修正线性激活函数的深度可分离卷积

试验中,采用 MobileNet 作为特征提取模型,旨在为深度神经网络硬件端嵌入式开发的可行性提供支撑。

3 试验结果

3.1 试验数据集及参数设置

试验使用自采的 X、Ka 双波段全极化对海检测识别抗干扰 R-D 数据集,在 R-D 数据上约占 30~60 个多普勒单元,50~150 个距离单元,其中有舰船和干扰两大类目标,舰船进一步细分为三个小类,舰船样本共 7624 帧,干扰样本共 1 901 帧,共有 9 525 帧,各类别数据分布数量如表 1 所示。试验中训练集和测试集比例为 7 : 3。

表1 试验中各类目标数据量分布

数据类别	数据量/帧
A 类舰船	7624
B 类舰船	1645
C 类舰船	3949
干扰	1901

雷达回波数据同可见光数据的目标检测任务存在较大差异,二者数据目标对比如图 7 所示,相较可见光数据,雷达回波数据目标辨识度更低,色彩、纹理信息更弱,识别难度更大,需要对目

标检测模型进行更特殊的设计。




图7 雷达回波数据和可见光数据对比图

本试验中,雷达回波数据及标注示例如图 8 所示,横坐标表示距离单元,纵坐标表示多普勒维度,从图 8 可以看出,目标有效区域在整个图中所占比例较小,这也增加了试验检测识别的难度。




图8 雷达回波数据中干扰及标注示意图

将标注结果整理为 Pascal VOC 格式的标注,如图 9 所示,可供深度神经网络模型训练框架直接读取。

```

1 <?xml version="1.0"?>
2 <annotations>
3   <folder>T1-15</folder>
4   <filename>T1-15_1.jpg</filename>
5   <path>D:\workspace\MyDatasets\Band-Low-RD-train\Band-Low-RD-101_2\result\T1-15\T1-15_1.jpg</path>
6   <source>
7     <database>Unknown</database>
8   </source>
9   <size>
10    <width>64</width>
11    <height>1024</height>
12    <depth>3</depth>
13  </size>
14  <segmented>0</segmented>
15  <object>
16    <name>T1</name>
17    <pose>Unspecified</pose>
18    <truncated>0</truncated>
19    <difficult>0</difficult>
20    <bndbox>
21      <xmin>28</xmin>
22      <ymin>507</ymin>
23      <xmax>41</xmax>
24      <ymax>621</ymax>
25    </bndbox>
26  </object>
27 </annotations>

```

图9 雷达回波数据标注文件示意图

模型训练参数上,采用的网络优化策略为随机梯度下降 (Stochastic Gradient Descent, SGD),初始学习率设置为 0.001,每 50 000 次迭代下降为原来的 10%。动量系数为 0.9,权值衰减系数为 0.000 5,训练迭代 120 000 次。

试验使用的操作系统是 window7_64, GPU NVIDIA GeForce 1080, Intel (R) Xeon (R) CPU E3-1225 v5 @3.30 GHz, pytorch1.5 CUDA 10.2 CUDNN7.6。

试验遵循在交并比 (Intersection over Union, IOU) 等于 0.5 时的均值平均精度 (mean Average Precision, mAP) 计算方法来评估模型性能,所有模型框架代码是基于 PyTorch 实现。试验中使用 mAP 指标评价检测算法性能,并保证训练集和测试集中没有相同数据, mAP 为各类别平均精度 (Average Precision, AP) 的均值, mAP 计算方法如式 (1) 所示。AP 定义来源于 Precision-Recall 曲线,是某类别 precision 值在 recall 值为 {0, 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 1} 时的平均值,其计算方法如式 (2) 所示。precision 为精确率, recall 为召回率,二者计算方法分别为式 (3) 和式 (4)。其中, TP 代表检测结果为真,且真值为真的检测框数量, FP 代表检测结果为真,但真值为假的检测框数量, FN 代表检测结果为假,但真值为真的检测框数量。

$$mAP = \text{Average}(AP \text{ for each object class}) \quad (1)$$

$$AP = \frac{1}{11} \sum_{precision, recall \in \{0, 0.1, \dots, 1\}} \quad (2)$$

$$precision = \frac{TP}{TP + FP} \quad (3)$$

$$recall = \frac{TP}{TP + FN} \quad (4)$$

3.2 试验结果与分析

3.2.1 干扰辨识性能试验

干扰辨识性能试验中涉及舰船 (包括三类舰船, 记为 T1) 与干扰 (记为 T2) 两类目标。试验采用两种特征提取模型, VGG 特征提取模型和 EfficientNet 特征提取模型, 采用 AD-CNN 检测网络结构^[14]。为比较 AD-CNN 检测算法与经典目标检测算法之间的检测性能差异, 本文选取具有代表性的恒虚警率检测方法 (Cell Averaging-

Constant False Alarm Rate, CA-CFAR)、自适应阈值分割 (OTSU) 和普通卷积神经网络 (Convolutional Neural Networks, CNN) 进行对比试验。

模型训练过程中进行相关参数的可视化展示, 绘制迭代训练过程中的损失、精度等参数曲线, VGG 和 Efficient 模型分别如图 10-11 所示。

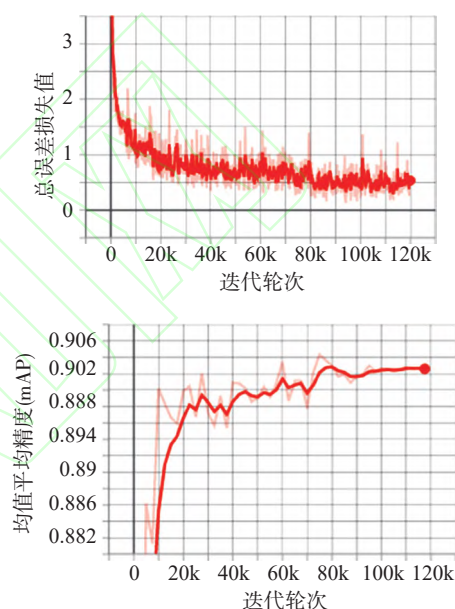


图 10 VGG-AD-CNN 训练数据图

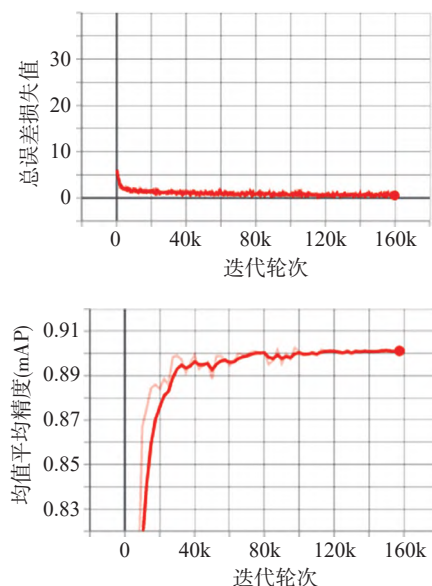


图 11 Efficient-AD-CNN 训练数据图

从数据图中可以看出,模型的损失函数在经历一定轮次的迭代之后,都呈现平滑的下降趋势,所有针对舰船、干扰检测识别任务模型均有效收敛。

测试阶段,针对测试数据,网络模型整体的试验结果如表2所示。

表2 舰船、干扰检测识别结果(准确率)

	舰船	干扰	平均
CA-CFAR	0.842	0.804	0.823
OTSU	0.883	0.839	0.861
CNN	0.971	0.877	0.924
AD-CNN(VGG)	0.995	0.941	0.968
AD-CNN(Efficient)	0.996	0.944	0.970

本文针对舰船(T1)、干扰(T2)类别的精度-召回率(PR)曲线如图12-13所示。

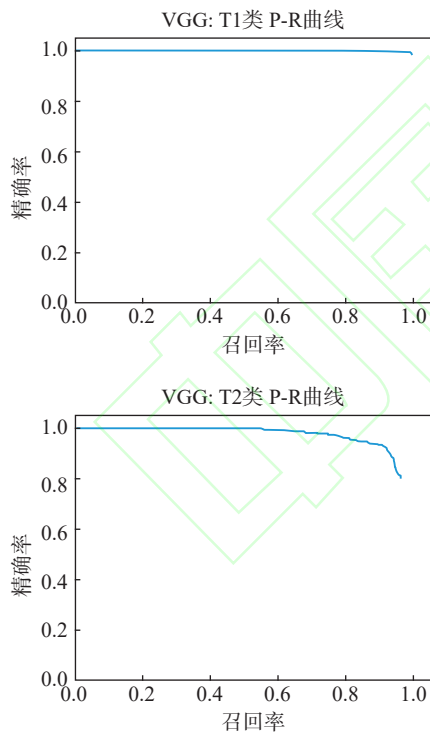


图12 舰船、干扰检测识别中AD-CNN(VGG)模型的PR曲线图

从试验结果可以看出,两种模型结构的整体性能相近,针对舰船类别(T1)均有较高的召回率和精度,可能源于舰船类别(T1)目标特征明显、区分度高,而干扰类别(T2)在召回率较高

的情况下,精度有所下降,可能是由于干扰类别(T2)目标较小,难以有效表征其信息特征。

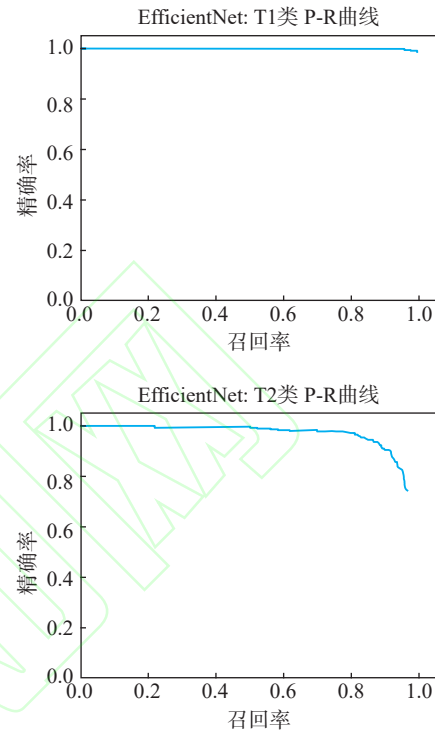


图13 舰船、干扰检测识别AD-CNN(Efficient)模型的PR曲线图

3.2.2 细粒度舰船、干扰辨识性能试验

细粒度舰船、干扰辨识性能试验涉及4类目标, A类舰船、干扰、B类舰船、C类舰船(小船), 分别用T1、T2、T3、T4来标注。采用VGG特征提取模型和EfficientNet特征提取模型模型训练过程中进行相关数据展示, 如图14-15所示。

由试验结果可以看出,模型的损失函数在经历一定轮次的迭代之后均呈现平滑的下降趋势,所有针对舰船、干扰检测识别任务模型均有效收敛。

测试阶段,为比较AD-CNN检测算法与经典目标检测算法之间的检测性能差异,本文选取具有代表性的恒虚警率检测方法、自适应阈值分割和普通卷积神经网络进行对比试验。针对测试数据,网络模型整体的试验结果如表3所示。

模型针对T1、T2、T3、T4类别的PR曲线分别如图16-17所示。




图 14 训练过程中AD-CNN(VGG)模型损失与精度的变化曲线

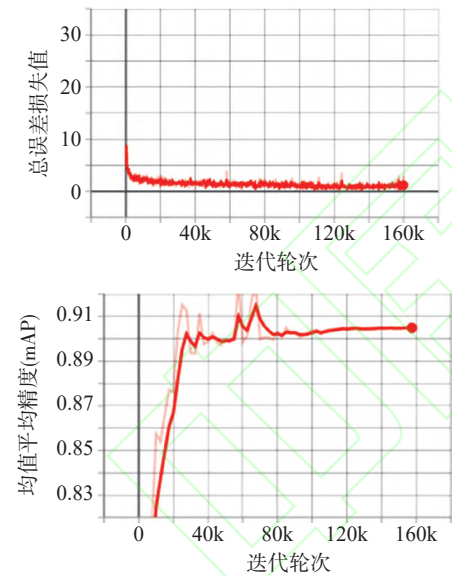


图 15 训练过程中AD-CNN(Efficient)模型损失与精度的变化曲线

表 3 细粒度舰船、干扰辨识性能试验结果

模型名称	A类 舰船	干扰	B类 舰船	C类 舰船	平均 准确率	模型大小 /MB
CA-CFAR	0.853	0.796	0.855	0.820	0.831	—
OTSU	0.889	0.833	0.893	0.872	0.872	—
CNN	0.960	0.898	0.957	0.928	0.936	190
AD-CNN (VGG)	0.998	0.934	0.993	0.966	0.973	184
AD-CNN (Efficient)	0.997	0.957	0.997	0.977	0.982	88.5




图 16 细粒度舰船、干扰检测识别AD-CNN(VGG)模型PR曲线图

由试验结果可以看出,对于T1目标类和T3目标类,模型都有较为优异的效果,可能原因是T1和T3两类都为大目标,特征信息比较明显,因此检测识别精确率和召回率都较高,而对于T2和T4,以准确率评价指标来衡量,Efficient具有最均衡的性能,但是从PR曲线中可以看出,VGG在高




图 17 细粒度舰船、干扰检测识别 AD-CNN(Efficient)模型的 PR 曲线图

召回率的情况下,精确率明显较高,原因可能是 VGG 具有最复杂的网络结构,其拟合能力也较强。

从整体来看 VGG 具有均衡的性能,但是模型体积也较大,模型对于 T1 和 T3 类的结果都优于 T2、T4, T1、T3 为大型目标,而 T2、T4 为小型目标。

3.2.3 轻量化模型识别试验

轻量模型的核心是优化特征提取网络,针对干扰辨识性能试验,采用结构优化的 MobileNet 特征提取网络模型(简称 Mobile 模型),更为轻量化^[15]。这是由于 Mobile 模型的基本单元是深度级可分离卷积和标准卷积,大大减少了计算量和模型参数量,训练过程中的模型损失和精度变化曲线如图 18 所示。

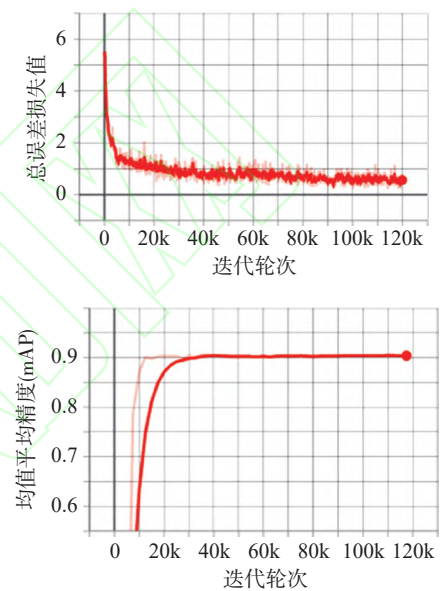


图 18 训练过程中 Mobile 模型损失与精度的变化曲线

模型的准确率如表 4 所示,由结果可见,采用 MobileNet 模型,准确率没有较大变化,但模型大小减少到 25 MB 以下,有利于弹载嵌入式平台的迁移。

表 4 舰船、干扰检测识别模型准确率、容量对比

模型名称	舰船	干扰	平均	容量/MB
AD-CNN(VGG)	0.995	0.941	0.968	184
AD-CNN(Efficient)	0.996	0.944	0.970	88.5
AD-CNN(Mobile)	0.994	0.948	0.971	23.4

模型针对舰船(T1)、干扰(T2)类别的精度-召回率(PR)曲线如图 19 所示。由试验结果可以得出,Mobile 轻量化检测模型对舰船和干扰两类目标的检测性能基本与 VGG 模型、Efficient 模型相同,但 Mobile 模型的大小约为前两者的 1/9 和 1/4。该模型部署在资源有限的嵌入式平台上更具

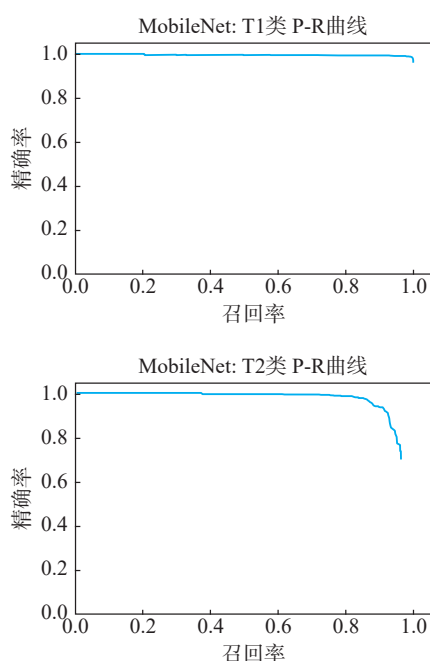


图19 舰船、干扰检测识别Mobile模型的PR曲线图

有潜力。

4 结 论

本文提出了一种基于深度神经网络的雷达导引头目标检测识别算法, 主要研究内容包括针对雷达回波目标检测提出的基于特征金字塔的AD-CNN算法, 通过特征金字塔的多尺度结构, 对于雷达R-D数据中的目标特征能够更好的进行表征, 并能有效处理细粒度目标、干扰检测识别任务, 并设计成统一端到端的网络结构; 针对神经网络特性, 采用轻量化网络结构, 便于后续嵌入式开发研究。并在收集到的雷达回波数据集上进行试验验证, 试验结果表明, 本文提出方法在干扰辨识和细粒度目标检测识别任务上都取得了较优异的性能, 进一步证明了本文将神经网络模型迁移到雷达数据领域中的可行性和适用性, 为后续开展雷达数据领域人工智能研究提供了借鉴意义。

[参 考 文 献]

[1] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic

segmentation [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2014: 580–587.

[2] Girshick R. Fast r-cnn [C]. Proceedings of the IEEE International Conference on Computer Vision, 2015: 1440–1448.

[3] Ren S, He K, Girshick R, et al. Faster r-cnn: towards real-time object detection with region proposal networks [C]. Advances in Neural Information Processing Systems, 2015: 91–99.

[4] He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37 (9): 1904–1916.

[5] Redmon J, Farhadi A. YOLOv3: an incremental improvement [J]. Computer Vision and Pattern Recognition, arXiv: 1804.02767, 2018.

[6] Liu W, Anguelov D, Erhan D, et al. SSD: single shot multibox detector [C]. European Conference on Computer Vision. Springer, Cham, 2016: 21–37.

[7] 张刚, 成建波, 李涛. 美国新一代远程反舰导弹发展概述 [J]. 飞航导弹, 2019, (12): 35–42.

[8] 宗凯彬, 张承龙, 卓志敏. 智能导弹武器系统发展综述 [J]. 现代防御技术, 2020, 48 (3): 48–55.

[9] 徐刚锋, 张旭荣, 张岩, 等. 人工智能技术在导弹武器装备领域的发展研究 [J]. 战术导弹技术, 2019, (5): 12–17.

[10] 胡仕友, 赵英海. 导弹武器智能精确制导技术发展分析 [J]. 战术导弹技术, 2017, (2): 1–5.

[11] 赵日, 赵鹏飞, 程运江, 等. 人工智能技术在反舰作战中的应用研究 [J]. 战术导弹技术, 2019, (5): 86–91.

[12] Lin T Y, Dollar P, Girshick R, et al. Feature pyramid networks for object detection [C]. IEEE Conference on Computer Vision and Pattern Recognition, 2017.

[13] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition [J]. Computer Vision and Pattern Recognition, arXiv: 1409.1556, 2014

[14] Tan M, Le Q V. Efficientnet: rethinking model scaling for convolutional neural networks [J]. Computer Vision and Pattern Recognition, arXiv: 1905.11946, 2019.

[15] Howard A G, Zhu M, Chen B, et al. Mobilenets: efficient convolutional neural networks for mobile vision applications [J]. Computer Vision and Pattern Recognition, arXiv: 1704.04861, 2017.